

Respostas à orientadora — Análise e discussão dos resultados (base técnica para o TCC)

Este documento amarra as **questões da orientadora à lógica do código** e aos **CSVs gerados** no repositório, para você copiar/adaptar a redação do capítulo de resultados e discussão.

Mapa pergunta → seção

Questão da orientadora	Onde está respondido
Tabela 2: ARIMA e SARIMA com os mesmos MAE/RMSE/MAPE — arredondamento? SARIMA sem sazonalidade? Amostra sem sazonalidade? Histórico inferior a 2 anos influencia?	§1 (+ <code>evidencia_arima_sarima_por_sku.csv</code> ; parágrafo <i>Comprimento de histórico</i>)
Figuras 5–7: diferença prática ARIMA vs SARIMA; ARIMA “acompanha a queda”	§2 (+ <code>resumo_quantitativo_figuras_5_7.csv</code> , <code>dados_numericos_figuras_5_7.csv</code>)
Melhor desempenho médio ARIMA/SARIMA: vale em todos os SKUs? Média móvel / Holt-Winters em alguns casos?	§4 (+ <code>taxa_vitoria_modelos_resumo.csv</code> , <code>vitoria_modelo_por_sku.csv</code>)
Inconsistência Resumo (Holt-Winters “melhor”) vs Tabela 2 (ARIMA/SARIMA)	§5

Arquivos de evidência (atualize após nova execução do pipeline):

Arquivo	
resultados/tabelas_tcc/evidencia_arima_sarima_por_sku.csv	Ordens (p,d,q) , previsões idênticas <code>gerar_figuras_tcc</code> <code>auditoria_arima_s</code> <code>comparar_modelos</code> use <code>heuristica_ma</code> como substituto p
resultados/tabelas_tcc/heuristica_mae_arima_vs_sarima_por_sku.csv	(Opcional) Por SKU partir de <code>candidat</code> gerado pelo <code>gerar</code> <code>python</code> <code>validacao/gerar_e</code>

	Quando existir <code>evidencia_arima_s</code> (inclui ordens e Al
resultados/tabelas_tcc/taxa_vitoria_modelos_resumo.csv	Quantos SKUs “ver (desempate MAE -
resultados/tabelas_tcc/medias_por_modelo_todos_candidatos_validos.csv	Médias de MAE/RI candidatos não co
resultados/tabelas_tcc/medias_por_modelo_apenas_top10_tcc.csv	Mesmas médias re na Tabela 2 / figur
resultados/tabelas_tcc/resumo_quantitativo_figuras_5_7.csv	MAE no horizonte, (unid./dia), desvio SKU das Figuras 5-
resultados/tabelas_tcc/dados_numericos_figuras_5_7.csv	Série dia a dia: rea numérica dos gráf
resultados/tabelas_tcc/criterio_selecao_figuras_5_7.json	SKU usado nas Fig fim da seleção em

Código relevante:

- Função `construir_auditoria_arima_sarima` e anexo ao `resultados` ao final de `comparar_modelos` : [modelos/comparacao_modelos_previsao.py](#).
- Seleção de candidatos, filtros e SKU das Fig. 5–7: [gerar_figuras_tcc.py](#) (`_rodar_comparacao_300_selecionar_10` , constantes `CV_TESTE_MIN` , `RANGE_TESTE_MIN` , `EPSILON_DIFF_MAE_TOP3` , etc.).
- Exportação agregada de CSVs: [modelos/evidencias_orientadora_tcc.py](#).
- Regeneração offline: [validacao/gerar_evidencias_de_candidatos_csv.py](#).

1. Por que ARIMA e SARIMA têm exatamente o mesmo MAE, RMSE e MAPE na Tabela 2?

Não é “só arredondamento”. Igualdade em três métricas ao mesmo tempo, SKU a SKU e na média do top-10, indica que **as previsões no período de teste são as mesmas** (ou diferem abaixo da precisão numérica), logo os erros são idênticos.

Mecanismo no código: o SARIMA mensal é estimado com `pmdarima.auto_arima(..., seasonal=True, m=30)` e o ARIMA com `seasonal=False` . O seletor por AIC pode escolher **ordem sazonal nula** $(P,D,Q) = (0,0,0)$ no SARIMA. Nesse caso, a parte sazonal **não entra** no modelo ajustado; se a parte não sazonal coincidir com a do ARIMA, as **previsões**

coincidem — o que você vê na tabela 2 e no arquivo `dados_numericos_figuras_5_7.csv` (valores previstos ARIMA = SARIMA).

Comprimento de histórico (sim, afeta — e o código já reflete isso em parte):

- **SARIMA anual** ($m=365$) nem sequer é estimado em `comparar_modelos` quando o treino tem **menos de 730 dias** (~2 anos): constante `MIN_DIAS_SARIMA_ANUAL` em [modelos/comparacao_modelos_previsao.py](#). Ou seja, com menos de 2 anos de dados **não** há comparação sazonalidade-anual vs não; só entram **SARIMA mensal** ($m=30$) e ARIMA.
- **Com qualquer extensão de série, mas sobretudo com histórico curto**, o critério de informação (AIC/BIC) tende a **penalizar parâmetros sazonais extra**: poucos graus de liberdade e muitos coeficientes sazonais tornam o ajuste instável ou sem ganho de verossimilhança; o passo de seleção do `auto_arima` pode então **manter** $(P,D,Q) = (0,0,0)$ no bloco sazonal.
- **Menos observações** também significam **menos ciclos completos** de um padrão $m=30$ (aproximação de “mês” em dias) e **mais ruído** em séries de **saldo** (degraus, reposição). Isso **reduz a identificabilidade** de sazonalidade forte ao nível do SKU e **reforça** a convergência para um modelo que se comporta como a **mesma estrutura ARIMA** nos dois ajustes.
- **Conclusão para o TCC**: a equivalência numérica ARIMA/SARIMA é **compatível** com a combinação (i) **sazonalidade nula escolhida** pelo `auto_arima`, (ii) **duração finita do treino** e (iii) natureza da série. **Não** implica que, com mais anos de dados e outro m , o SARIMA não pudesse diferir — mas **neste desenho empírico** o efeito do histórico limitado é **plausível e esperado** em metodologia de séries temporais.

Evidência numérica (snapshot do repositório, SKU das Fig. 5–7 = 7460): em

`resumo_quantitativo_figuras_5_7.csv`, as linhas **ARIMA** e **SARIMA** têm o mesmo `mae_horizonte_teste`, `rmse_horizonte_teste`, mesma `inclinacao_previsao_unid_por_dia` e mesmas médias dos primeiros/últimos 7 dias — ou seja, **curvas idênticas** no horizonte exibido.

Evidência em lote: em `evidencia_arima_sarima_por_sku.csv`, entre os **66** SKUs com teste não constante, **62** têm `previsoes_arima_sarima_identicas == True` e **65** têm

`sarima_PDQ_todos_zeros == True` — confirma empate de previsões e **componente sazonal nula** $(P,D,Q)=(0,0,0)$ na quase totalidade dos casos (substituto parcial:

`heuristica_mae_arima_vs_sarima_por_sku.csv` via script de validação, se existir).

Texto sugerido para o TCC: a sazonalidade **agregada** (exploratória) pode ser forte no negócio, mas a **série diária de saldo por SKU** é frequentemente dominada por **degraus** (reposição) e **médias móveis implícitas**; o $m=30$ é uma aproximação de mês em dias. O `auto_arima` minimiza AIC no **treino** e pode preferir **não** usar sazonalidade estimável sem ganho — **reforçado** quando o treino **não cobre vários anos completos** (ver parágrafo *Comprimento de histórico*). A **equivalência ARIMA/SARIMA** na tabela reflete isso, e não invalida o uso do SARIMA como **procedimento** que *permite* sazonalidade quando os dados a justificam.

2. Figuras 5, 6 e 7: o ARIMA “acompanha melhor a queda” e o SARIMA parece igual — qual a diferença prática?

Para o SKU escolhido para as figuras (critério abaixo), quando ARIMA e SARIMA são o mesmo vetor de previsão, não há diferença prática entre Fig. 6 e Fig. 7 além do rótulo: a discussão deve reconhecer isso ou escolher outro SKU em que `diff_mae_top3` separe bem os três modelos.

Onde está a diferença real neste SKU (7460): compare Holt-Winters com ARIMA/SARIMA usando `resumo_quantitativo_figuras_5_7.csv`:

- **Inclinação da previsão** (`inclinacao_previsao_unid_por_dia`): ARIMA/SARIMA forte **negativa** (queda contínua no horizonte); Holt-Winters **positiva** leve (previsão não acompanha a queda acentuada do real).
- **MAE no horizonte**: Holt-Winters **substancialmente maior** que ARIMA/SARIMA no mesmo arquivo.
- **Estabilidade**: desvio padrão das previsões de Holt-Winters é **menor** que o de ARIMA/SARIMA neste recorte — ou seja, HW fica “mais plano” em torno de um patamar, enquanto ARIMA/SARIMA seguem uma trajetória decrescente mais íngreme (ainda que não capturem quedas bruscas do real).

Frase modelo: “No SKU ilustrado, ARIMA e SARIMA coincidem numericamente; a distinção relevante é entre esses modelos e Holt-Winters, com MAE maior e trajetória de previsão menos alinhada à redução do estoque no teste.”

3. Critério de escolha do SKU das Figuras 5–7 (justificativa metodológica)

Objetivo: evitar SKUs com **teste quase constante** (todos os modelos acertam igual) e favorecer **diferença visível** entre Holt-Winters, ARIMA e SARIMA.

1. Pool de até 300 SKUs pré-filtrados na análise exploratória.
2. Para cada um, `comparar_modelos` com divisão treino/teste e métricas.
3. **Exclusões**: `teste_constante` ; `cv_teste < CV_TESTE_MIN` (5%); `range_teste < RANGE_TESTE_MIN` (20 un.); `max(MAE)-min(MAE) < EPSILON_MAE_IGUAL` entre todos os modelos.
4. **Top 10** para figuras comparativas e Tabela 2: menores **melhores MAE** entre elegíveis.
5. **SKU das Fig. 5–7**: entre os primeiros `min(30, número de elegíveis)` (na prática, às vezes menos de 30 se poucos SKUs passam nos filtros), ordena-se por maior `diff_mae_top3` (HW vs ARIMA vs SARIMA); se o SKU representativo da Fig. 4 aparecer nesse conjunto e seu MAE não for >10% pior que o melhor do pool, **prioriza-se** para coerência narrativa. O valor exato está em `critério_selecao_figuras_5_7.json` → `parametros_script.N_POOL_FIG`.

Constantes em `gerar_figuras_tcc.py`: `CV_TESTE_MIN`, `RANGE_TESTE_MIN`, `EPSILON_MAE_IGUAL`, `EPSILON_DIFF_MAE_TOP3`, `N_MELHORES`, `N_CANDIDATOS`.

4. “ARIMA/SARIMA tiveram melhor desempenho médio” — todos os SKUs se comportaram assim?

Não. A média na Tabela 2 é só sobre os 10 SKUs selecionados por **baixo erro**; isso não implica que **todo** o universo favoreça ARIMA/SARIMA.

Taxa de vitória (menor MAE por SKU, candidatos com teste não constante) — desempate **MAE → RMSE → MAPE**, igual a `modelos/evidencias_orientadora_tcc.py` e a `validacao/gerar_evidencias_de_candidatos_csv.py` (versões antigas usavam `idxmin` no `pivot` e distorciam empates). Snapshot em `taxa_vitoria_modelos_resumo.csv`:

Modelo	SKUs vencedores (%)
SARIMA Mensal (m=30)	60,61%
Suavização exponencial (Holt-Winters)	34,85%
Média móvel (7 dias)	3,03%
ARIMA Simples	1,52%

Interpretação: a maior parte das “vitórias” rotuladas como SARIMA coincide com MAE **idêntico ao ARIMA** (ver `heuristica_mae_arima_vs_sarima_por_sku.csv`): trata-se do **mesmo desempenho** com dois nomes; o desempate só escolhe um rótulo. A **suavização exponencial** vence em parcela relevante dos SKUs (~35% no snapshot atual), à parte desse bloco.

Médias no conjunto amplo (66 candidatos válidos, `medias_por_modelo_todos_candidatos_validos.csv`**)**: a ordenação típica por **MAE médio** é: **ARIMA ≤ SARIMA < Holt-Winters < Média móvel** (valores de referência no CSV versionado: ARIMA e SARIMA ligeiramente melhores que Holt-Winters; MM pior). Ou seja, Holt-Winters **não** é o melhor em média nesse recorte, mas também **não** é o pior — fica **entre** os modelos autorregressivos e a média móvel.

No subconjunto top-10 da Tabela 2, `medias_por_modelo_apenas_top10_tcc.csv` mostra médias **piores** para Holt-Winters e MM do que para ARIMA/SARIMA — reflexo do **critério de seleção** dos 10 melhores, não de uma “lei” para todos os produtos.

5. Inconsistência: Resumo do TCC diz que a suavização exponencial foi a melhor em média, mas a Tabela 2 destaca

exponencial foi a melhor em média, mas a tabela 2 destaca ARIMA/SARIMA

Isso é uma **contradição textual** a corrigir na versão final.

- A **Tabela 2** e `medias_por_modelo_apenas_top10_tcc.csv` refletem o **top-10** escolhido por menor MAE entre elegíveis: nesse recorte, **ARIMA e SARIMA** apresentam menores médias que Holt-Winters.
- O **Resumo** que afirma superioridade da suavização exponencial pode corresponder a **outra rodada, outra amostra de SKUs** (ex.: comparação otimizada por giro em `comparacao_top_skus_otimizado.py`) ou **redação desatualizada**.

Como harmonizar (escolha uma e mantenha em Resumo, Abstract e Conclusão):

1. Se o pipeline oficial é `gerar_figuras_tcc.py` : alinhe o Resumo à Tabela 2 e explique que a média refere-se ao **conjunto dos 10 SKUs** usados na comparação principal.
2. Se a conclusão correta for a suavização exponencial no conjunto amplo: atualize a Tabela 2 e o critério de seleção dos 10 SKUs, ou apresente **duas** tabelas (médias no pool 300 vs. médias no top-10) com interpretação explícita.

6. O que fazer após alterar dados ou parâmetros

1. `python gerar_figuras_tcc.py` — recalcula tudo, incluindo `evidencia_arima_sarima_por_sku.csv` e `critério_selecao_figuras_5_7.json` .
2. Se só quiser atualizar agregados a partir de `candidatos_300_metricas.csv` já existente: `python validacao/gerar_evidencias_de_candidatos_csv.py` (taxa de vitória com desempate MAE→RMSE→MAPE; **não** usar `idxmin` por coluna em pivots com empates).

7. Verificação após `python gerar_figuras_tcc.py` (prático + teórico)

O script não altera este ficheiro `.md` automaticamente. Os números abaixo foram conferidos com os CSVs após uma execução bem-sucedida (log com `CONCLUIDO` , figuras `figura1.png – figura7.png` , `tabela_02_desempenho_modelos.csv` , `evidencia_arima_sarima_por_sku.csv`).

Verificação	Resultado esperado
Execução	<code>resultados/logs/log_execucao_*.txt</code> termina com <code>CONCLUIDO</code> ; sem <code>Traceback</code> .
Figuras	<code>resultados/figuras_tcc/figura1.png</code> ... <code>figura7.png</code> .

Evidência ARIMA/SARIMA	<code>evidencia_arima_sarima_por_sku.csv</code> existe; colunas <code>sarima_PDQ_todos_zeros</code> , <code>previsoes_arima_sarima_identicas</code> .
Critério Fig. 5–7	<code>critério_selecao_figuras_5_7.json</code> com <code>sku_figuras_5_a_7</code> e <code>parametros_script</code> .

Snapshot coerente com o repositório (última verificação):

- **66** SKUs com teste não constante no pool analisado nos agregados; **62** deles com `previsoes_arima_sarima_identicas == True` em `evidencia_arima_sarima_por_sku.csv` — alinha com a §1 (equivalência numérica frequente).
- **65** desses 66 com `sarima_PDQ_todos_zeros == True` ($(P,D,Q)=(0,0,0)$ no componente sazonal) — **prova direta** de que o `auto_arima` escolheu sazonalidade nula na maior parte dos casos (teoria: SARIMA colapsa a um comportamento tipo ARIMA sobre a mesma série).
- **Taxa de vitória** no `taxa_vitoria_modelos_resumo.csv` (SARIMA 60,61% / Holt 34,85% / MM 3,03% / ARIMA 1,52%) mantém-se; interpretação na §4 (rótulo SARIMA vs empates com ARIMA).
- **Fig. 5–7** (`resumo_quantitativo_figuras_5_7.csv`): SKU **7460**; ARIMA e SARIMA com métricas idênticas; Holt-Winters com MAE de horizonte maior — coerente com a §2.
- `parametros_script.N_POOL_FIG` : pode ser **menor que 30** (ex.: 20) se o número de SKUs **elegíveis** após filtros for inferior a 30; o texto da §3 fala em “até 30” — corresponde a `min(30, len(elegiveis))` no código.

Teoria (Box–Jenkins / `pmdarima`): ordem sazonal $(0,0,0)$ com `m=30` significa que **nenhum** coeficiente AR/MA/D sazonal foi estimado; as previsões coincidem com um ARIMA puro quando (p,d,q) também coincidem — como visto nas linhas de `evidencia_arima_sarima_por_sku.csv` (ex.: $(0,1,0)$ para ambos e AIC igual). **Histórico inferior a 2 anos** no treino (típico neste caso) reforça o ponto da §1: o pipeline **não** ajusta SARIMA anual sem ~730 dias de treino; com menos dados, a seleção por AIC favorece ainda mais **parcimônia** no bloco sazonal.

Prático: se `heuristica_mae_arima_vs_sarima_por_sku.csv` não existir, não é falha do pipeline; use `evidencia_arima_sarima_por_sku.csv` ou gere a heurística com `python validacao/gerar_evidencias_de_candidatos_csv.py` .

Documento de apoio à revisão do TCC. Atualize os parágrafos com percentagens se regenerar dados: a §7 resume a última conferência cruzada código ↔ CSVs